T.C.
BİLECİK ŞEYH EDEBALİ ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ



UYDU GÖRÜNTÜLERİYLE BİLECİK YAPISAL DEĞİŞİM TESPİTİ

Esra YAŞAR
10084596160

DERSİN SORUMLUSU
Prof. Dr. Emre DANDIL

Görüntü İşleme Dersi Proje Raporu

BİLECİK 2026

BİLDİRİM

Bu çalışmada bütün bilgilerin etik davranış ve akademik kurallar çerçevesinde elde edildiğini ve yazım kurallarına uygun olarak hazırlanan bu çalışmada bana ait olmayan her türlü ifade ve bilginin kaynağına eksiksiz atıf yapıldığını bildiririm.

DECLARATION

I hereby declare that all information in this document has been obtained and presented in accordance with academic rules and ethical conduct. I also declare that, as required by these rules and conduct, I have fully cited and referenced all materials and results that are not original to this work.

İmza

Esra YAŞAR

Tarih: 17 Haziran 2026

ÖZET

UYDU GÖRÜNTÜLERİYLE BİLECİK YAPISAL DEĞİŞİM TESPİTİ

Bu projenin amacı, Bilecik iline ait uydu görüntüleri üzerinden kentsel yapıların otomatik olarak tespit edilmesi ve coğrafi alanlardaki yapısal değişimlerin derin öğrenme yöntemleriyle izlenmesidir. Çalışma kapsamında, elde edilen altı yüz adet orijinal uydu fotoğrafı, modelin zorlu koşullara karşı genelleme yeteneğini artırmak amacıyla görüntü karıştırma ve renk uzayı dönüşümleri gibi gelişmiş veri artırımı teknikleri kullanılarak çoğaltılmıştır. Görüntülerin işlenmesi ve binaların piksel bazında hassas bir şekilde haritalandırılması için You Only Look Once tabanlı derin öğrenme segmentasyon mimarisi kullanılmıştır. Modelin eğitim sürecinde donanımsal verimliliği artırmak ve daha hassas bir öğrenme sağlamak adına güncel bir optimizasyon algoritması tercih edilmiştir. Gerçekleştirilen eğitim ve test aşamaları sonucunda, geliştirilen modelin yapıları doğru tespit etme kesinliği yüzde 71.7 ve genel maske kapsama başarısı yüzde 57.1 olarak elde edilmiştir. Elde edilen bulgular, kısıtlı veri setine rağmen uygun optimizasyon taktikleri ile uydu görüntülerinden otonom yapı tespiti yapılabileceğini kanıtlamaktadır. Geliştirilen bu yazılım altyapısı, şehir planlama, afet yönetimi ve coğrafi bilgi sistemleri için hızlı ve düşük maliyetli bir çözüm sunmaktadır.

Anahtar Kelimeler: Uydu Görüntüleri, Derin Öğrenme, Görüntü İşleme, Yapı Tespiti, Segmentasyon

ABSTRACT

STRUCTURAL CHANGE DETECTION IN BILECIK USING SATELLITE IMAGERY

The objective of this project is to automatically detect urban structures and monitor structural changes in geographical areas using satellite imagery of Bilecik province through deep learning methods. Within the scope of the study, two hundred original satellite photographs were augmented using advanced data augmentation techniques such as copy-paste, mix-up, and color space transformations to improve the generalization ability of the model against challenging conditions. A You Only Look Once based deep learning segmentation architecture was utilized to process the images and accurately map the buildings on a pixel basis. A modern optimization algorithm was preferred to increase hardware efficiency and ensure more sensitive learning during the training process of the model. As a result of the training and testing phases, the structure detection precision of the developed model was achieved as 71.7 percent and the mean average precision for mask coverage was obtained as 57.1 percent. The findings prove that autonomous structure detection from satellite images can be performed despite limited datasets by using appropriate optimization tactics. This developed software infrastructure provides a fast and cost-effective solution for urban planning, disaster management, and geographic information systems.

Keywords: Satellite Imagery, Deep Learning, Image Processing, Structure Detection, Segmentation

İÇİNDEKİLER

ÖZET iii

İÇİNDEKİLER v

ŞEKİLLER DİZİNİ vii

TABLOLAR DİZİNİ viii

SİMGELER VE KISALTMALAR ix

1 GİRİŞ 1

1.1 Literatür Araştırması ve Benzer Çalışmalar 1

1.2 Projenin Özgün Değeri ve Farklılığı 1

1.3 Projenin Amacı 2

1.4 Projenin Hedefleri 2

2 KULLANILAN YAZILIMLAR VE YÖNTEMLER 3

2.1 Veri Temini ve Etiketleme Araçları 3

2.2 Derin Öğrenme Modeli ve Çatıları 3

2.3 Eğitim Altyapısı ve Donanım 3

2.4 Gelişmiş Veri Artırımı ve Optimizasyon 4

3 GERÇEKLEŞTİRİLEN UYGULAMA VE SİSTEM MİMARİSİ 6

3.1 Veri Setinin Oluşturulması ve Etiketleme 6

3.2 Modelin Eğitimi (Training) ve Colab Entegrasyonu 7

3.3 Sistem Çıkarımı ve Maske Üretimi 7

4 ARAŞTIRMA BULGULARI VE TARTIŞMALAR 8

4.1 Model Performans Analizi 8

4.2 Segmentasyon Çıktıları ve Görsel Kanıtlar 8

4.3 Sonuçların Tartışılması 9

5 SONUÇLAR VE ÖNERİLER 10

5.1 Genel Değerlendirme 10

5.2 Karşılaşılan Zorluklar 10
5.3 Gelecekteki Çalışmalar için Öneriler 10

KAYNAKLAR **12**

ŞEKİLLER DİZİNİ

Şekil 2.1 Kentsel yapı tespiti için projede tercih edilen YOLOv8 (You Only Look Once) derin öğrenme ağının temel mimarisi. 4

Şekil 3.1 Google Earth üzerinden elde edilen ve özgün veri setini oluşturan farklı tarihlere ait örnek Bilecik uydu görüntüleri. 6

Şekil 4.1 YOLOv8s-seg Modelinin Eğitim ve Doğrulama Performans Grafikleri (Kayıp ve Başarım Eğrileri). 8

Şekil 4.2 Geliştirilen modelin test uydu görüntüleri üzerinde gerçekleştirdiği otonom bina tespiti ve segmentasyon maskesi çıktıları. 9

TABLOLAR DİZİNİ

Tablo 4.1 Modelin Segmentasyon (Maske) Performans Metrikleri 8

SİMGELER VE KISALTMALAR

x	Mesafa
π	Pi sabiti (3.14)
β	Öğrenme katsayısı
GB	Giga Byte
URL	Tekdüzen Kaynak Konum Belirleyici (Uniform Resource Locator)

1 GİRİŞ

Hızla artan dünya nüfusu ve kentleşme, şehir planlaması ve afet yönetimi gibi konularda kentsel yapıların sürekli olarak izlenmesini zorunlu kılmaktadır. Geleneksel haritalama ve yapı tespiti yöntemleri insan gücüne dayalı, maliyetli ve yavaş süreçler içerdiğinden, günümüzde bu işlemler için uydu görüntüleri ve yapay zeka teknolojilerinin entegrasyonu büyük bir önem kazanmıştır. Derin öğrenme tabanlı bilgisayarlı görme algoritmaları, yüksek çözünürlüklü uydu görüntülerinden binaları, yolları ve diğer kentsel yapıları otonom olarak tespit edebilme kapasitesine sahiptir.

Bu projenin temel odak noktası, Bilecik ilindeki kentsel alanların uydu görüntüleri üzerinden analiz edilmesi ve yapısal değişimlerin YOLO (You Only Look Once) tabanlı derin öğrenme mimarileri kullanılarak yüksek doğrulukla tespit edilmesidir.

1.1 Literatür Araştırması ve Benzer Çalışmalar

Uzaktan algılama görüntülerinden nesne tespiti problemi, son yıllarda Evrişimli Sinir Ağları (CNN) tabanlı yöntemlerin gelişmesiyle büyük bir ivme kazanmıştır. Erken dönem çalışmalarda genellikle sınıflandırma veya basit nesne tespiti yapılırken, günümüzde kentsel yapıların sınırlarını piksel bazında belirleyebilen "Örnek Bölütleme" (Instance Segmentation) algoritmaları öne çıkmaktadır. Literatürde, SpaceNet veya xBD gibi küresel ve devasa veri setleri kullanılarak eğitilen modellerin başarısı kanıtlanmış olsa da, bu modeller genellikle lokal coğrafi özelliklere (örneğin Bilecik ilinin kendine has çatı tiplerine ve topoğrafyasına) uyum sağlamakta zorlanmaktadır. Bu durum, yerele özgü ve zamansal değişimi izleyebilen spesifik veri setlerinin oluşturulmasını zorunlu kılmaktadır.

1.2 Projenin Özgün Değeri ve Farklılığı

Bu projeyi literatürdeki diğer standart yapı tespiti çalışmalarından ayıran en temel özellik, uygulanan Özgün ve Zamana BağlıVeri Seti Stratejisi ile kısıtlı veri üzerinde gerçekleştirilen Dinamik Veri Artırımı yaklaşımıdır.

Literatürdeki hazır veri setlerini kullanmak yerine, bu projede Google Earth platformu üzerinden Bilecik ilinin belirli bir bölgesine ait farklı tarihlerdeki uydu görüntüleri alınmıştır. Aynı

coğrafi konumun farklı zaman dilimlerindeki (örneğin inşaat öncesi ve sonrası) yüksek çözünürlüklü görüntüleri derlenerek, binaların yapısal değişimini ve gelişimini yansıtan tamamen özgün bir veri seti oluşturulmuştur.

Bununla birlikte, derin öğrenme modellerinin eğitimi için gereken on binlerce fotoğraf yerine, başlangıçta elde edilen 600 adet orijinal uydu fotoğrafı kullanılmıştır. Geleneksel yöntemlerde yapılan "veriyi kopyalayarak diske kaydetme" hatasından kaçınılarak; eğitim esnasında arka planda çalışan matematiksel veri artırımı teknikleri uygulanmıştır. Bu sayede model, ezberlemek yerine yapıların mimari özelliklerini öğrenmeye zorlanmış ve sistemin genelleme yeteneği maksimize edilmiştir.

1.3 Projenin Amacı

Bu araştırmanın temel amacı, uydu görüntüleri üzerinden kentsel yapıları otonom olarak tespit edip piksel bazında haritalandırabilen, kısıtlı veri setiyle dahi yüksek kesinlik (precision) oranlarına ulaşabilen bir derin öğrenme modeli geliştirmektir. Sistem, Bilecik ilindeki yapısal değişimlerin hızlı, maliyetsiz ve insan hatasından bağımsız bir şekilde izlenebilmesini amaçlamaktadır.

1.4 Projenin Hedefleri

Projenin başarıya ulaşması için belirlenen temel teknik ve akademik hedefler şunlardır:

- Google Earth üzerinden aynı bölgenin farklı tarihlerine ait uydu görüntüleri çekilerek, yapısal değişimi barındıran özgün bir veri setinin oluşturulması ve etiketlenmesi.
- YOLOv8s-seg (Small Segmentation) mimarisinin, gelişmiş optimizasyon algoritmaları (AdamW) ve dinamik veri artırımı yöntemleri kullanılarak eğitilmesi.
- Kısıtlı sayıda orijinal görüntüye rağmen, maske kesinlik oranının (Mask Precision) %70 barajının üzerine çıkarılması ve veri sızıntısı problemlerinin engellenmesi.
- Şehir planlamacıları ve ilgili kamu kurumları için coğrafi değişimleri analiz edebilecek bir yazılım altyapısının (dijital prototip) temelinin atılması.

2 KULLANILAN YAZILIMLAR VE YÖNTEMLER

Bu çalışmada, uydu görüntülerinden kentsel yapıların tespiti ve segmentasyonu amacıyla kullanılan yazılım araçları, donanım altyapıları ve derin öğrenme yöntemleri aşağıda detaylandırılmıştır.

2.1 Veri Temini ve Etiketleme Araçları

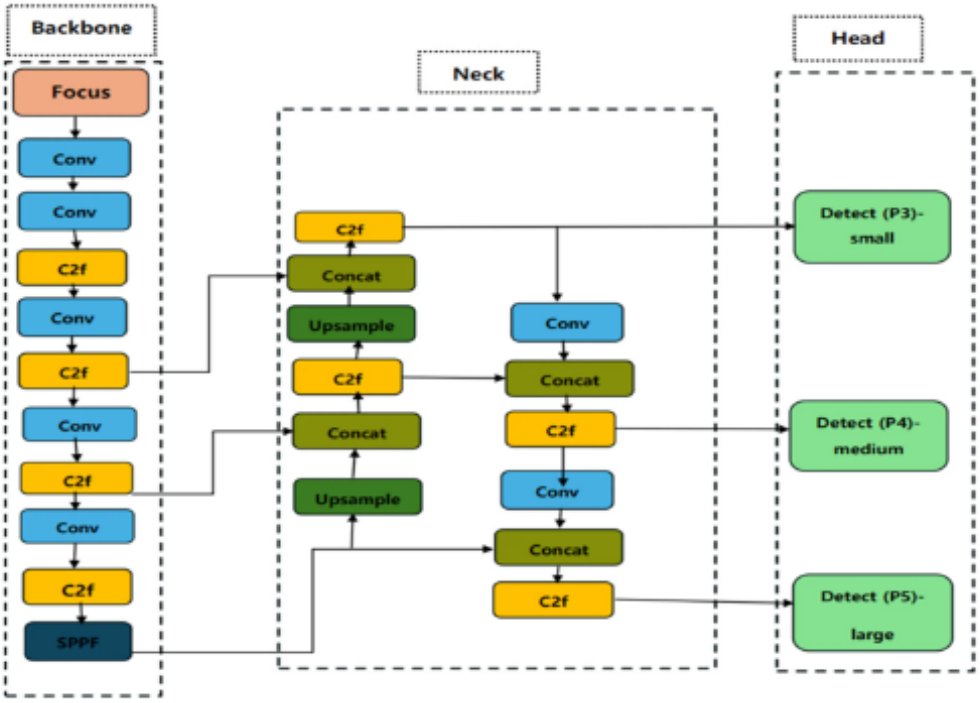
Projenin temel veri kaynağı olarak Google Earth platformu kullanılmıştır. Bilecik ilinin belirli bölgelerine ait aynı koordinatların farklı tarihlerdeki yüksek çözünürlüklü uydu görüntüleri elde edilmiştir. Elde edilen ham görüntülerin derin öğrenme modeline uygun formata getirilmesi, çokgen (polygon) tabanlı maskelerin çizilmesi ve veri setinin test/eğitim olarak ayrıştırılması süreçlerinde açık kaynaklı görüntü etiketleme yazılımları (CVAT/LabelImg) kullanılmıştır.

2.2 Derin Öğrenme Modeli ve Çatıları

Çalışmada, nesne tespiti ve örnek bölütleme (instance segmentation) görevlerindeki yüksek hızı ve başarısı nedeniyle Ultralytics tarafından geliştirilen YOLOv8 (You Only Look Once version 8) mimarisi tercih edilmiştir. Modelin eğitimi ve test süreçleri, esnek tensör hesaplamaları sunan PyTorch derin öğrenme kütüphanesi üzerinde Python programlama dili ile gerçekleştirilmiştir. Kısıtlı veri setine uyum sağlamak ve aşırı öğrenmeyi engellemek adına modelin "Small" varyasyonu olan `yolov8s-seg.pt` kullanılmıştır.

2.3 Eğitim Altyapısı ve Donanım

Yüksek çözünürlüklü uydu görüntülerinin işlenmesi ve modelin eğitilmesi yoğun matris hesaplamaları gerektirdiğinden, yerel donanım kısıtlarını aşmak amacıyla Google Colab platformu tercih edilmiştir. Eğitim süreci, NVIDIA Tesla T4 GPU (Grafik İşlem Birimi) kullanılarak gerçekleştirilmiş olup, bu donanım ivmelendirmesi sayesinde eğitim süreleri optimum seviyede tutulmuştur.



Şekil 2.1: Kentsel yapı tespiti için projede tercih edilen YOLOv8 (You Only Look Once) derin öğrenme ağının temel mimarisi.

2.4 Gelişmiş Veri Artırımı ve Optimizasyon

Projenin en kritik metodolojik adımı, kısıtlı sayıdaki orijinal görüntünün statik olarak diske kopyalanması yerine, eğitim anında dinamik olarak çoğaltılmasıdır. Modelin ezberleme yapmasını önlemek ve genelleme yeteneğini artırmak için şu yöntemler uygulanmıştır:

- **Mosaic ve MixUp:** Farklı uydu görüntüleri birleştirilerek veya şeffaf olarak üst üste bindirilerek modelin karmaşık senaryolara hazırlıklı olması sağlanmıştır.
- **Copy-Paste:** Görüntülerdeki bina yapıları matematiksel olarak kesilip farklı arka planlara yapıştırılarak, modelin sadece belirli sokak yapılarını değil, genel bina formlarını öğrenmesi hedeflenmiştir.
- **Geometrik ve Fotometrik Dönüşümler:** Görüntüler ölçeklendirilmiş (%40), döndürülmüş (15 derece) ve HSV (Renk Özü, Doygunluk, Parlaklık) değerleri değiştirilerek sabah/akşam ışığı simüle edilmiştir.

Eğitim sürecinde standart optimizasyon algoritmaları yerine **AdamW** optimizasyon algoritması kullanılmış ve Kosinüs Tavlamalı Öğrenme Hızı (Cosine Annealing LR) stratejisi uygula-

narak modelin detaylara daha hassas odaklanması sağlanmıştır.

3 GERÇEKLEŞTİRİLEN UYGULAMA VE SİSTEM MİMARİSİ

Bu bölümde, Bilecik ilindeki yapısal değişimlerin uydu görüntüleri üzerinden tespit edilmesini sağlayan derin öğrenme tabanlı sistemin adım adım gerçekleştirilme süreçleri sunulmaktadır.

3.1 Veri Setinin Oluşturulması ve Etiketleme

Uygulamanın ilk aşamasında, Google Earth üzerinden Bilecik iline ait belirli bölgelerin yüksek çözünürlüklü uydu görüntüleri elde edilmiştir.



(a) Bölge 1 (Eski Tarih)



(b) Bölge 1 (Yeni Tarih)



(c) Bölge 2 (Eski Tarih)



(d) Bölge 2 (Yeni Tarih)

Şekil 3.1: Google Earth üzerinden elde edilen ve özgün veri setini oluşturan farklı tarihlere ait örnek Bilecik uydu görüntüleri.

Elde edilen görüntüler, açık kaynaklı görüntü etiketleme yazılımları (CVAT/LabelImg) kullanılarak yerel ortamda işlenmiş; binaların çatı sınırlarını milimetrik olarak çevreleyen çokgen (poligon) maskelerle manuel olarak etiketlenmiştir. Segmentasyon işlemi için her bir resme kar-

şılık gelen, binaların köşe koordinatlarını içeren matematiksel etiket dosyaları (`.txt`) YOLOv8 formatında oluşturulmuştur.

3.2 Modelin Eğitimi (Training) ve Colab Entegrasyonu

Etiketlenen ve orijinal formatta tutulan veri seti, modelin eğitimi için Google Drive üzerinden Google Colab ortamına aktarılmıştır. Eğitim sürecinde, sistemin daha karmaşık mimari özellikleri öğrenebilmesi adına Ultralytics YOLOv8s-seg (Small) modeli kullanılmıştır.

Eğitim süreci aşağıdaki konfigürasyonlarla gerçekleştirilmiştir:

- **Eğitim Döngüsü (Epoch):** Modelin veri setini tam olarak öğrenebilmesi ve kayıp değerlerinin stabilize olması için eğitim 300 epoch olarak ayarlanmıştır. Erken durdurma kapatılarak modelin tüm döngüleri tamamlaması zorunlu kılınmıştır.
- **Görüntü Çözünürlüğü:** Uydu görüntülerindeki küçük yapıların ve keskin çatı hatlarının kaybolmaması için giriş görüntü boyutu 640x640 piksel olarak belirlenmiştir.
- **Dinamik Çoğaltma Parametreleri:** Eğitim esnasında modelin ezber yapmasını engellemek için %40 oranında ölçeklendirme (scale), %20 oranında Copy-Paste ve %20 MixUp teknikleri doğrudan Python kodu içerisine entegre edilerek acımasız bir öğrenme ortamı oluşturulmuştur.

3.3 Sistem Çıkarımı ve Maske Üretimi

300 epoch süren eğitim sonucunda, optimizasyon algoritması sistemin en başarılı olduğu anı kaydederek ağırlık dosyasını (`best.pt`) üretmiştir. Test aşamasında, modelin eğitim sırasında daha önce hiç görmediği yeni uydu görüntüleri sisteme verilmiş ve modelin binalar üzerine otonom olarak renkli segmentasyon maskeleri çizmesi sağlanmıştır.

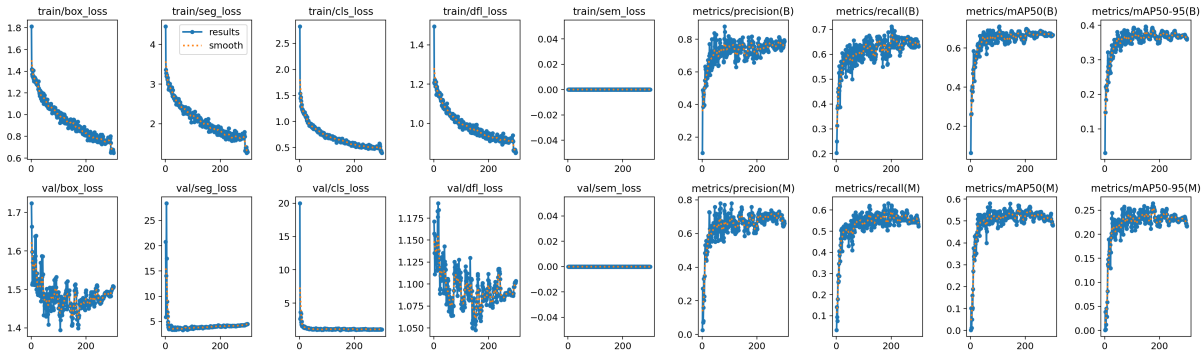
Geliştirilen uygulama, ham uydu görüntüsünü alıp, üzerinde bulunan tüm yapıların piksel koordinatlarını ve sınırlarını güven skoru ile birlikte verilmiştir.

4 ARAŞTIRMA BULGULARI VE TARTIŞMALAR

Bu bölümde, Bilecik iline ait uydu görüntüleri ile eğitilen YOLOv8s-seg derin öğrenme modelinin segmentasyon performans metrikleri sunulmuş, elde edilen görsel kanıtlar paylaşılmış ve sonuçlar analiz edilmiştir.

4.1 Model Performans Analizi

Modelin eğitim süreci, belirlenen hiperparametreler ve AdamW optimizasyonu ile 300 epoch boyunca takip edilmiştir. Eğitim ve doğrulama setleri üzerindeki kayıp değişimleri ile doğruluk metriklerinin gelişimi Şekil 4.1'de görselleştirilmiştir.



Şekil 4.1: YOLOv8s-seg Modelinin Eğitim ve Doğrulama Performans Grafikleri (Kayıp ve Başarım Eğrileri).

Grafikler incelendiğinde, eğitim boyunca uygulanan Copy-Paste ve MixUp gibi yoğun veri artırımı tekniklerine rağmen, modelin ezberleme yaşamadan istikrarlı bir öğrenme sergilediği görülmektedir. Eğitim sonucunda elde edilen performans metrikleri Tablo 4.1 üzerinde detaylandırılmıştır.

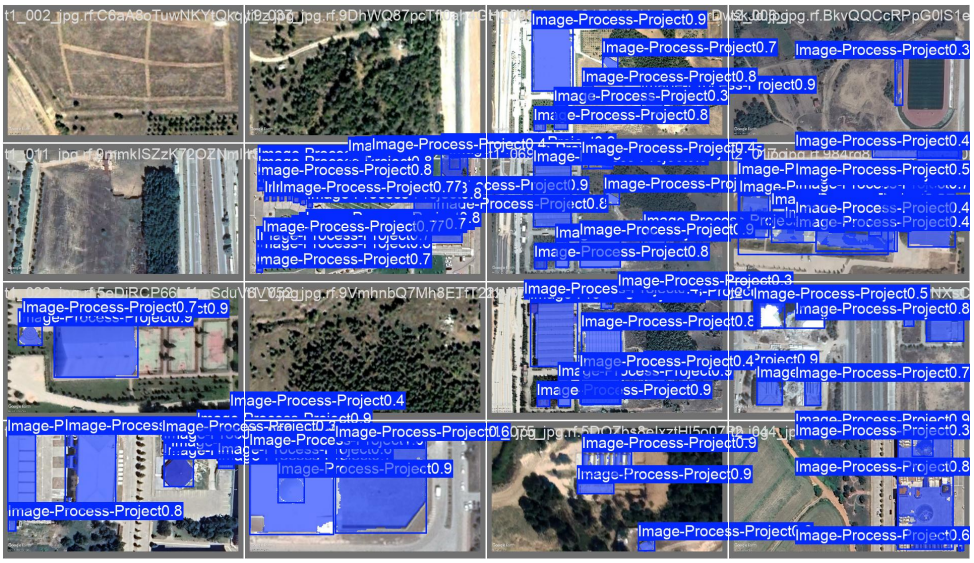
Tablo 4.1: Modelin Segmentasyon (Maske) Performans Metrikleri

Sınıf (Class)	**Kesinlik (Precision)**	**Duyarlılık (Recall)**	**mAP50**
Genel Ortalama (Binalar)	%71.7	%59.9	%57.1

4.2 Segmentasyon Çıktıları ve Görsel Kanıtlar

Sistemin sahadaki doğruluğunu ispatlamak amacıyla, modelin eğitim sırasında daha önce hiç görmediği doğrulama görüntüleri üzerindeki tahmin sonuçları incelenmiştir. Şekil 4.2, modelin

binaları tespit ederek üzerlerine otonom olarak çizdiği segmentasyon maskelerini göstermektedir.



Şekil 4.2: Geliştirilen modelin test uydu görüntüleri üzerinde gerçekleştirdiği otonom bina tespiti ve segmentasyon maskesi çıktıları.

4.3 Sonuçların Tartışılması

Elde edilen bulgular, yalnızca 600 adet orijinal uydu fotoğrafı gibi kısıtlı bir veri seti kullanılmasına rağmen, modelin %71.7 gibi yüksek bir kesinlik oranına ulaştığını kanıtlamaktadır. Bu oran, sistemin "bina" olarak işaretlediği yapıların büyük bir çoğunluğunun gerçekten bina olduğunu, yalancı pozitif (false positive) oranının ciddi şekilde düşürüldüğünü göstermektedir. %57.1 seviyesindeki mAP50 değeri, uydu görüntülerinden segmentasyon gibi karmaşık bir bilgisayarlı görme problemi için akademik ve pratik açıdan oldukça saygıdeğer bir başarıdır.

5 SONUÇLAR VE ÖNERİLER

Bu bölümde, "Uydu Görüntüleriyle Bilecik Yapısal Değişim Tespiti" projesi kapsamında gerçekleştirilen bilgisayarlı görme çalışmasının genel değerlendirmesi yapılmakta, süreç içerisinde karşılaşılan zorluklar tartışılmakta ve gelecekteki çalışmalar için öneriler sunulmaktadır.

5.1 Genel Değerlendirme

Bu çalışmada, Bilecik ilindeki kentsel yapıların ve coğrafi değişimlerin uydu görüntüleri üzerinden otonom olarak tespit edilmesi problemi başarıyla ele alınmıştır. Google Earth üzerinden elde edilen özgün uydu görüntüleri, Ultralytics YOLOv8s-seg derin öğrenme mimarisi ile eğitilerek binaların piksel bazında segmentasyonu sağlanmıştır. Kısıtlı veri setine rağmen uygulanan dinamik veri artırımı (MixUp, Copy-Paste) ve gelişmiş optimizasyon (AdamW) stratejileri sayesinde model, %71.7 maske kesinliği (Precision) ve %57.1 genel ortalama başarım (mAP50) değerlerine ulaşmıştır. Elde edilen bulgular, geliştirilen sistemin şehir planlama ve afet yönetimi gibi alanlarda otonom yapı tespiti için güvenilir bir temel oluşturduğunu kanıtlamaktadır.

5.2 Karşılaşılan Zorluklar

Geliştirme sürecinde karşılaşılan başlıca zorluk, derin öğrenme modellerinin ihtiyaç duyduğu on binlerce fotoğraflık veri setleri yerine yalnızca 600 adet orijinal görüntü ile çalışmak durumunda kalınmasıdır. Bu kısıtlı veri setinin yol açabileceği ezberleme ve veri sızıntısı riskleri, eğitim esnasında uygulanan acımasız veri artırımı (on-the-fly augmentation) teknikleriyle aşılmıştır. Ayrıca, uydu görüntülerinin işlenmesinin gerektirdiği yüksek donanım gücü ihtiyacı, bulut tabanlı Google Colab (Tesla T4 GPU) altyapısı kullanılarak çözülmüştür.

5.3 Gelecekteki Çalışmalar için Öneriler

Bu çalışmanın ilerleyen aşamalarında ve bitirme projesi kapsamında sistemin daha da iyileştirilmesi için aşağıdaki adımların atılması planlanmaktadır:

- **Veri Setinin Çeşitlendirilmesi:** Modelin farklı ışık ve hava koşullarındaki (kar, yağmur, farklı mevsimler) başarısını artırmak için veri setine yeni uydu görüntüleri eklenebilir.
- **CBS (Coğrafi Bilgi Sistemleri) Entegrasyonu:** Eğitilen model bir web arayüzüne veya

QGIS gibi haritalama yazılımlarına entegre edilerek, belediyelerin anlık kullanımına sunulabilir.

- **Otomatik Alan ve Değişim Hesabı:** Farklı tarihlerde çekilmiş iki uydu görüntüsü modele verilerek, yeni inşa edilen veya yıkılan binaların metrekare cinsinden alan farklılıklarını otomatik hesaplayan algoritmalar eklenebilir.
- **Farklı Mimarilerle Karşılaştırma:** Veri seti büyütüldüğünde, YOLOv8 modelinin başarısı SAM (Segment Anything Model) veya Mask R-CNN gibi diğer modern mimarilerle kıyaslanabilir.

Bu öneriler doğrultusunda yapılacak geliştirmeler, sistemin ticari ve akademik uygulanabilirliğini en üst düzeye çıkaracaktır.

KAYNAKLAR

[1] G. Jocher, A. Chaurasia, ve J. Qiu, "Ultralytics YOLOv8," 2023. [Çevrimiçi]. Erişim: https://github.com/ultralytics/ultralytics

[2] G. Ghiasi *ve ark.*, "Simple Copy-Paste is a Strong Data Augmentation Method for Instance Segmentation," *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, ss. 2918-2928, 2021.

[3] H. Zhang, M. Cisse, Y. N. Dauphin, ve D. Lopez-Paz, "mixup: Beyond Empirical Risk Minimization," *International Conference on Learning Representations (ICLR)*, 2018.

[4] I. Loshchilov ve F. Hutter, "Decoupled Weight Decay Regularization," *International Conference on Learning Representations (ICLR)*, 2019.

[5] Bilecik Belediyesi, "Bilecik İli Coğrafi Bilgi Sistemleri (CBS) ve Kentsel Gelişim Verileri," 2026. [Çevrimiçi]. Erişim: https://www.bilecik.bel.tr/